

Robot internetowy i graf WWW - sprawozdanie

Paulina Brzęcka

22 kwietnia 2025

SPIS TREŚCI

1	WSTĘP	3
1.1	Wstęp	3
1.2	Opis działania crawlera	3
1.3	Wielowątkowość	4
1.3.1	Analiza wyników	4
1.3.2	Wnioski	5
2	Analiza grafu wynikowego	6
2.1	Liczba wierzchołków i łuków	6
2.2	Analiza składowych spójności grafu	6
2.2.1	Wnioski	7
2.3	Analiza rozkładów stopni (in-degree, out-degree)	8
2.3.1	Rozkład in-degree	8
2.3.2	Rozkład out-degree	8
2.3.3	Wnioski	9
2.4	Analiza najkrótszych ścieżek w grafie	9
2.4.1	Wyniki dla największej SCC	9
2.4.2	Rozkład średnich odległości	10
2.4.3	Rozkład promieni	10
2.4.4	Wnioski	11
2.5	Analiza współczynników klasteryzacji	11
2.5.1	Wyniki	12
2.5.2	Rozkład klasteryzacji w skali log-log	12
2.5.3	Wnioski	13
2.6	Analiza spójności wierzchołkowej	13
2.6.1	Interpretacja	14
2.6.2	Wnioski	14
3	Odporność na awarie i ataki	15
3.1	Odporność na awarie i ataki	15
3.1.1	Awaria - usunięcie 10% losowych wierzchołków	15
3.1.2	Atak - usunięcie 10% wierzchołków o najwyższym stopniu	16
3.1.3	Awaria - usunięcie 30% losowych wierzchołków	17
3.1.4	Atak - usunięcie 30% wierzchołków o najwyższym stopniu	19
3.1.5	Awaria - usunięcie 50% losowych wierzchołków	20

3.1.6	Atak - usunięcie 50% wierzchołków o najwyższym stopniu	21
3.1.7	Podsumowanie	23
4	Pagerank	25
4.1	Analiza PageRank	25
4.1.1	Rozkład PageRank bez tłumienia ($d = 1.0$)	25
4.1.2	Rozkład PageRank z tłumieniem ($d = 0.85$)	25
4.1.3	Zbieżność PageRank dla różnych wartości tłumienia	26
4.1.4	Wnioski	28
5	Podsumowanie	29

1. WSTĘP

1.1 Wstęp

Celem projektu było stworzenie systemu do analizy struktury sieci WWW uczelni zagranicznej. Głównie zadanie polegało na zaprojektowaniu i zaimplementowaniu robota internetowego, który przegląda zasoby w obrębie wskazanej domeny, zapisuje je lokalnie, a następnie buduje skierowany graf połączeń pomiędzy stronami. Uzyskany graf stanowił podstawę do przeprowadzenia dalszych analiz topologicznych. Wybrana uczelnia zagraniczna to Uniwersytet Maltański <https://www.um.edu.mt/>.

Crawler został zaimplementowany w języku Python z wykorzystaniem takich bibliotek jak `threading`, `queue`, `networkx`, `tqdm` oraz standardowych narzędzi do parsowania stron. Obsługuje on wielowątkowe pobieranie dokumentów, przestrzega zasad `robots.txt` oraz automatycznie analizuje strukturę połączeń między stronami w czasie rzeczywistym.

1.2 Opis działania crawlera

Zaimplementowany crawler działa w oparciu o architekturę kolejki zadań i dynamicznie zarządzanych wątków. Działa w sposób asynchroniczny i dostosowuje liczbę aktywnych wątków w zależności od aktualnego obciążenia. Poniżej przedstawiono szczegóły działania:

- **Inicjalizacja:** Crawler przyjmuje adres początkowy (URL) oraz maksymalną liczbę stron do odwiedzenia. Tworzona jest kolejka adresów oraz struktury do przechowywania odwiedzonych stron i grafu połączeń.
- **Zarządzanie wątkami:** Funkcja `run_crawler()` odpowiada za dynamiczne uruchamianie nowych wątków w miarę potrzeb. Wątki są tworzone tylko wtedy, gdy kolejka zadań nie jest pusta i liczba aktywnych wątków nie przekracza zadeklarowanego limitu.
- **Wątek roboczy:** Każdy wątek wykonuje funkcję `child_thread()`, która:
 - sprawdza, czy dana strona może być pobrana (zgodność z `robots.txt`),
 - pobiera stronę przy użyciu funkcji `download_page()`,
 - parsuje zawartość HTML i wyciąga linki (`extract_links()`),
 - aktualizuje zbiór odwiedzonych stron i graf (z wykorzystaniem blokad synchronizujących `threading.Lock`).
- **Kończenie pracy:** Crawler kończy działanie, gdy:
 - osiągnięto maksymalną liczbę odwiedzonych stron,
 - kolejka zadań jest pusta i nie ma aktywnych wątków.

Synchronizacja wątków odbywa się z wykorzystaniem mechanizmu `Condition`, co pozwala na usypianie i wybudzanie procesu głównego w zależności od sytuacji.

- **Wizualizacja postępu:** Podczas działania wyświetlany jest pasek postępu przy użyciu bi-


bioteki t_{qdm}, który pozwala śledzić liczbę przetworzonych stron.

1.3 Wielowątkowość

Crawler został uruchomiony z różną liczbą wątków: 1, 2, 4, 8 i 16, gdzie liczba odwiedzonych stron została ustawiona na przynajmniej 1000. Testy na wątkach przeprowadzono na mniejszej liczbie wierzchołków ze względu na czas działania programu, dla 3000 stron przedstawiałyby się one wizualnie podobnie. Dla każdej konfiguracji zmierzono czas działania, a także zarejestrowano liczbę odwiedzonych wierzchołków i zbudowanych krawędzi w grafie.

Tabela 1.1: Wyniki działania crawlera dla różnych liczby wątków dla przynajmniej 1000 stron

Liczba wątków	Czas (s)	Wierzchołki	Krawędzie
1	2912.54	1000	55208
2	1373.82	1000	54778
4	731.47	1000	54684
8	516.76	1001	53075
16	387.61	1000	54182



Rysunek 1.1: Wykres czasu crawlowania w stosunku do liczby wątków dla przynajmniej 1000 stron.

1.3.1 Analiza wyników

- Zauważalny jest wyraźny spadek czasu działania wraz ze wzrostem liczby wątków. Przejście z 1 do 2 wątków skróciło czas ponad dwukrotnie.

- Kolejne wzrosty liczby wątków również przynoszą korzyści, różnice te stają się coraz mniejsze (np. różnica między 8 a 16 wątkami to tylko 129 s).
- Dla testu z 16 wątkami osiągnięto średnią prędkość pobierania około 0,39 sekundy na stronę.

1.3.2 Wnioski

Crawler bardzo dobrze skalował się w zakresie 1-8 wątków. Dalsze zwiększanie liczby wątków nadal poprawiało czas, lecz z mniejszym zyskiem. Możliwe wąskie gardła to:

- ograniczenia sieciowe lub po stronie serwera,
- opóźnienia wynikające z synchronizacji wątków (blokady),
- zróżnicowana głębokość eksplorowanych ścieżek.

Optymalną liczbą wątków w tym środowisku wydaje się być 8 lub 16. Dlatego docelowo crawler został puszczony na 16 wątkach.

2. ANALIZA GRAFU WYNIKOWEGO

2.1 Liczba wierzchołków i łuków

Wynikowy graf ma 3011 wierzchołków i 309748 krawędzi.

2.2 Analiza składowych spójności grafu

Aby zrozumieć strukturę badanego grafu WWW, przeprowadzono analizę składowych spójności. W grafach skierowanych wyróżniamy kilka typów składowych:

WCC (Weakly Connected Component) składowa spójności słaba — zbiór wierzchołków, pomiędzy którymi istnieje ścieżka, jeśli zignorujemy kierunki krawędzi.

SCC (Strongly Connected Component) składowa spójności silna — zbiór wierzchołków, w którym dla każdej pary (u, v) istnieją ścieżki $u \rightarrow v$ oraz $v \rightarrow u$ z zachowaniem kierunku.

IN zbiór wierzchołków, z których można dotrzeć do SCC, ale nie można z SCC wrócić do nich.


OUT zbiór wierzchołków, które można osiągnąć z SCC, ale nie można z nich wrócić do SCC.

TENDRILS / ISLANDS wierzchołki, które nie należą do SCC, IN ani OUT — np. lokalne połączenia boczne lub całkowicie odizolowane wyspy.

Graf kondensacji SCC (G_{SCC}) graf, w którym każda silnie spójna składowa zostaje zredukowana do jednego wierzchołka. Jest to graf skierowany acykliczny (DAG), reprezentujący zależności pomiędzy składowymi.

- **Liczba słabych składowych spójności (WCC)** wynosi 1, co oznacza, że cały graf jest słabo spójny — można przejść między dowolnymi dwoma wierzchołkami ignorując kierunek krawędzi.
- **Liczba silnych składowych spójności (SCC)** to 1677. Największa z nich (tzw. **CORE**) zawiera 1251 wierzchołków. CORE odpowiada centralnej części sieci WWW, w której strony są silnie ze sobą połączone w obu kierunkach.
- **IN** zawiera 1750 wierzchołków prowadzących do SCC, ale niedostępnych z niej.
- **OUT** zawiera 7 wierzchołków, do których można dotrzeć z SCC, ale które nie prowadzą z powrotem do niej.
- **TENDRILS / ISLANDS** to tylko 3 wierzchołki — minimalna liczba wskazująca na wysoką spójność globalną.
- **Graf kondensacji (G_{SCC})** zawiera 1677 wierzchołków (po jednej dla każdej SCC) oraz 8280 krawędzi, co świadczy o gęstym połączeniu między komponentami.

Graf SCC (kondensacja silnie spójnych składowych)



Rysunek 2.1: Graf kondensacji G_{SCC} — każda kropka to jedna silnie spójna składowa

2.2.1 Wnioski

Na podstawie powyższej analizy można zauważyć, że struktura badanego grafu WWW jest zgodna z klasycznym modelem sieci WWW:

- Występuje dominująca składowa silnie spójna (CORE), do której prowadzi bardzo duża liczba wierzchołków (IN).
- Komponent OUT jest marginalny, co wskazuje na małą liczbę „wyjść” ze strony do innych części sieci.
- Niewielka liczba tendrili oraz wysp (ISLANDS) wskazuje na dobrze połączoną strukturę sieci.
- Analiza grafu kondensacji pokazuje złożone relacje pomiędzy poszczególnymi silnie spójnymi komponentami.

Taka struktura jest charakterystyczna dla rzeczywistych sieci hipertekstowych i potwierdza hipotezę tzw. modelu **bow-tie**, w którym występują wyraźne obszary CORE, IN i OUT. Model ten jest przydatny do analizy skalowalnych sieci (np. WWW, sieci społecznościowe), ponieważ ujawnia kluczowe komponenty odpowiedzialne za przepływ informacji oraz identyfikuje potencjalne punkty podatne na awarie.

2.3 Analiza rozkładów stopni (in-degree, out-degree)


W celu określenia struktury połączeń w grafie WWW przeanalizowano rozkład stopni wierzchołków — zarówno wejściowych (in-degree), jak i wyjściowych (out-degree). W typowych sieciach skali bezwzględnej oczekuje się, że rozkłady te będą podlegać rozkładowi potęgowemu, czyli:

$$P(k) \sim k^{-\alpha}$$

Aby to zweryfikować, wykonano regresję liniową w skali log-log, co pozwala oszacować wykładnik potęgowy α oraz współczynnik dopasowania R^2 .

2.3.1 Rozkład in-degree

- Współczynnik potęgowy: $\alpha \approx 0.43$
- Współczynnik determinacji: $R^2 = 0.361$




Rysunek 2.2: Rozkład in-degree w skali log-log z dopasowaną funkcją potęgową

Pomimo pewnej tendencji do zachowania rozkładu potęgowego, niskie R^2 wskazuje, że dopasowanie nie jest idealne. Może to świadczyć o obecności zakłóceń (np. odcięcia w zakresie małych lub bardzo dużych stopni), lub że sieć nie jest klasycznie skali bezwzględna.

2.3.2 Rozkład out-degree

- Współczynnik potęgowy: $\alpha \approx -0.34$ (odwrotność, ponieważ rośnie)
- Współczynnik determinacji: $R^2 = 0.069$



Rysunek 2.3: Rozkład out-degree w skali log-log z dopasowaną funkcją potęgową

Dla rozkładu out-degree uzyskano bardzo niskie R^2 , co oznacza słabe dopasowanie modelu potęgowego do danych. Może to wskazywać, że stopnie wyjściowe są bardziej jednorodne (np. wiele stron ma podobną liczbę linków wychodzących), co zaburza rozkład potęgowy.

2.3.3 Wnioski

Rozkłady stopni w badanym grafie tylko częściowo spełniają cechy sieci skali bezwzględnej. Chociaż rozkład in-degree wykazuje lekką tendencję do zachowania funkcji potęgowej, to out-degree jest znacznie mniej uporządkowany. Możliwe przyczyny to:

- specyfika lokalnej struktury strony uczelni (dużo stron głównych linkujących do wielu zasobów),
- ograniczenia crawl (limit liczby stron),
- zaburzenia wynikające z dynamicznych linków lub zasobów zewnętrznych.

2.4 Analiza najkrótszych ścieżek w grafie

Aby zbadać strukturę odległości w sieci, przeanalizowano najkrótsze ścieżki pomiędzy wszystkimi parami wierzchołków w największej silnie spójnej składowej (SCC). W tego typu grafach często występuje efekt tzw. *małego świata*, czyli niska średnia odległość pomiędzy wierzchołkami.

2.4.1 Wyniki dla największej SCC

- Średnia odległość pomiędzy parami wierzchołków: **2,67**


- Średnica grafu (najdłuższa najkrótsza ścieżka): 7

2.4.2 Rozkład średnich odległości

Dla każdego wierzchołka obliczono średnią odległość do pozostałych. Histogram tych wartości przedstawiono na rysunku 2.4. Następnie przeprowadzono dopasowanie funkcji potęgowej w skali log-log:

$$f(x) \sim x^{-9,23}, \quad R^2 = 0,76$$


Uzyskane dopasowanie wskazuje na stosunkowo dobre odwzorowanie rozkładu funkcją potęgową, co sugeruje obecność centralnych węzłów o krótkich ścieżkach do reszty grafu.



Rysunek 2.4: Histogram średnich odległości z wierzchołków

2.4.3 Rozkład promieni

Promień wierzchołka to największa odległość do innego wierzchołka w jego komponentach. Histogram promieni przedstawia rysunek 2.5.



Rysunek 2.5: Histogram promieni (maksymalnych odległości)

Zdecydowana większość wierzchołków ma promień równy 6, co sugeruje dobrą spójność i relatywnie płaską strukturę wewnątrz głównego komponentu SCC.

2.4.4 Wnioski

Analiza odległości potwierdza obecność zjawiska **małego świata** w strukturze grafu — większość stron jest osiągalna w maksymalnie kilku krokach. Histogramy wskazują na spójność i przewidywalność rozkładu odległości. Wyniki te są charakterystyczne dla naturalnie powstających grafów WWW.

2.5 Analiza współczynników klasteryzacji

Współczynniki klasteryzacji opisują, w jakim stopniu sąsiedzi danego wierzchołka również są ze sobą połączeni, czyli jak lokalnie „gęsta” jest struktura grafu. Dla grafu WWW można je traktować jako miarę grupowania stron o podobnej tematyce lub powiązanych funkcjonalnie.


Wyróżniamy dwa typy klasteryzacji:

- **Lokalny współczynnik klasteryzacji (C_v)** — liczony osobno dla każdego wierzchołka jako stosunek liczby istniejących połączeń między sąsiadami do liczby możliwych połączeń.
- **Globalny współczynnik klasteryzacji (C)** — średnia z lokalnych współczynników lub liczony jako stosunek trykątów do trójek możliwych.

2.5.1 Wyniki

- Globalny współczynnik klasteryzacji: **0,6949**
- Liczba wierzchołków z $C_v > 0$: **3008**

Histogram lokalnych współczynników klasteryzacji przedstawiono na rysunku 2.6. Dane te sugerują, że znaczna część wierzchołków ma wysoki poziom lokalnego grupowania, co wskazuje na obecność silnie powiązanych podstruktur w grafie.




Rysunek 2.6: Histogram lokalnych współczynników klasteryzacji

2.5.2 Rozkład klasteryzacji w skali log-log

Aby ocenić, czy wartości lokalnego współczynnika klasteryzacji podlegają rozkładowi potęgowemu, przeprowadzono analizę regresji w skali log-log. Otrzymano następujące wyniki:

$$f(x) \sim x^{0,37}, \quad R^2 = 0,03$$

Niski współczynnik determinacji R^2 świadczy o bardzo słabym dopasowaniu modelu potęgowego. Oznacza to, że rozkład lokalnych współczynników klasteryzacji nie podlega funkcji potęgowej.



Rysunek 2.7: Rozkład lokalnej klasteryzacji (log-log) z regresją potęgową

2.5.3 Wnioski

Analiza współczynników klasteryzacji wykazuje, że:

- Graf cechuje się wysokim globalnym poziomem klasteryzacji ($C \approx 0,69$), co jest typowe dla grafów sieciowych (np. WWW, sieci społecznościowe).
- Większość wierzchołków posiada dodatni współczynnik lokalny, często bliski 1 — co wskazuje na obecność licznych lokalnych struktur typu „kliki”.
- Rozkład lokalnej klasteryzacji nie podlega prawu potęgowemu, co może być skutkiem ograniczeń topologicznych strony uczelni (np. sztywne szablony, sekcje z wieloma wewnętrznymi linkami).

2.6 Analiza spójności wierzchołkowej

Spójność wierzchołkowa określa minimalną liczbę wierzchołków, które należy usunąć z grafu, aby stał się niespójny (czyli został rozdzielony na co najmniej dwie osobne składowe).

- Jeżeli spójność wierzchołkowa wynosi $k = 1$, to istnieje co najmniej jeden **punkt artykulacji** — wierzchołek, którego usunięcie prowadzi do rozspojenia grafu.
- Jeżeli $k = 2$, to potrzebne są co najmniej dwa usunięcia (tzw. **pary wierzchołków rozspajających**).

W analizowanym grafie największej silnie spójnej składowej (SCC) uzyskano następujące wyniki:

- **Spójność wierzchołkowa:** 1
- Znalaziono 2 **punkty artykulacji**, których usunięcie rozdziela graf:
 - <https://www.um.edu.mt/research/ethics/researchethicsatum/>
 - <https://www.um.edu.mt/>

2.6.1 Interpretacja

Obecność zaledwie dwóch punktów artykulacji oznacza, że graf jest ogólnie dobrze połączony, ale zawiera krytyczne wierzchołki, których usunięcie skutkuje przerwaniem ciągłości sieci. Są to zazwyczaj centralne lub nadrzędne strony (np. strona główna uczelni), do których prowadzi wiele połączeń i które pośredniczą w dostępie do innych podstron.

2.6.2 Wnioski

- Spójność wierzchołkowa na poziomie $k = 1$ świadczy o względnej odporności strukturalnej, choć nie całkowitej — atak na jeden kluczowy wierzchołek może zakłócić komunikację w obrębie grafu.
- Zidentyfikowane punkty artykulacji mogą stanowić potencjalne punkty awarii lub „wąskie gardła” w strukturze sieci.
- W kontekście projektowania struktur WWW warto dążyć do większej nadmiarowości połączeń, aby zminimalizować wpływ usunięcia jednego centralnego zasobu.

3. ODPORNOŚĆ NA AWARIE I ATAKI

3.1 Odporność na awarie i ataki

W celu zbadania strukturalnej odporności analizowanego grafu WWW przeprowadzono symulacje dwóch typów zaburzeń:







- **Awarie** — losowe usuwanie 10%, 30% oraz 50% wierzchołków.
- **Ataki** — celowe usuwanie 10%, 30% oraz 50% wierzchołków o największym stopniu.

Dla każdej modyfikacji przeprowadzono analizę składowych spójności (WCC, SCC, struktura bow-tie), rozkładów stopni, średnich odległości, współczynników klasteryzacji oraz spójności wierzchołkowej.

3.1.1 Awaria - usunięcie 10% losowych wierzchołków

- Wierzchołki: 2710, Krawędzie: 253956
- Największa SCC: 1133 wierzchołki
- Średnia odległość: 2.67, średnica: 7
- Globalna klasteryzacja: 0.697
- Spójność wierzchołkowa: 1, punkt artykulacji: <https://www.um.edu.mt/>

Graf SCC (kondensacja silnie spójnych składowych)




3.1.2 Atak - usunięcie 10% wierzchołków o najwyższym stopniu


- Wierzchołki: 2710, Krawędzie: 10090
- Największa SCC: 397 wierzchołków
- Średnia odległość: 5.88, średnica: 18
- Globalna klasteryzacja: 0.179

- Graf niespójny - brak sensu szukać punktów artykulacji


Graf SCC (kondensacja silnie spójnych składowych)




Rozkład In-degree




Rozkład Out-degree




Histogram średnich odległości z wierzchołków




Histogram średnich odległości z wierzchołków



Histogram lokalnych współczynników klasteryzacji



Rozkład lokalnej klasteryzacji (log-log)










3.1.3 Awaria - usunięcie 30% losowych wierzchołków

- Wierzchołki: 2108, Krawędzie: 159559
- Największa SCC: 574


- Średnia odległość: 2.63, średnica: 9
- Globalna klasteryzacja: 0.721
- Punkty artykulacji: <https://www.um.edu.mt/>, <https://www.um.edu.mt/research/ethics/researchethicsaturn/>

Graf SCC (kondensacja silnie spójnych składowych)



3.1.4 *Atak - usunięcie 30% wierzchołków o najwyższym stopniu*


- Wierzchołki: 2108, Krawędzie: 3014
- Największa SCC: 85
- Średnia odległość: 5.26, średnica: 17
- Globalna klasteryzacja: 0.1757
- Graf niespójny - brak sensu szukać punktów artykulacji



3.1.5 Awaria - usunięcie 50% losowych wierzchołków

- Wierzchołki: 1506, Krawędzie: 72649
- Największa SCC: 573
- Średnia odległość: 2.73, średnica: 6
- Globalna klasteryzacja: 0.6195

- Punkty artykulacji: 2 (jak wcześniej)









3.1.6 Atak - usunięcie 50% wierzchołków o najwyższym stopniu

- Wierzchołki: 1506, Krawędzie: 3014
- Największa SCC: 85

- Średnia odległość: 5.26, średnica: 17
- Globalna klasteryzacja: 0.2460
- Graf niespójny

Graf SCC (kondensacja silnie spójnych składowych)



3.1.7 Podsumowanie

Wyniki symulacji wskazują na istotne różnice w zachowaniu grafu w zależności od typu zakłócenia (awaria losowa vs atak ukierunkowany). Poniżej przedstawiono szczegółowe wnioski:

Składowe spójności

- **Awarye losowe** nie naruszają znacząco struktury spójności:
 - nawet przy 50% usuniętych wierzchołków liczba WCC = 2,
 - największa SCC pozostaje względnie duża (573 wierzchołków),
 - struktura typu bow-tie zostaje zachowana (IN/OUT obecne, TENDRILS minimalne).
- **Ataki** natomiast:
 - szybko rozbijają graf (np. już przy 10% - ponad 1200 WCC),
 - SCC staje się bardzo mała (np. tylko 85 wierzchołków przy 30-50%),
 - rośnie liczba wysp i tendrili (ponad 1000 dla 50%),
 - graf traci strukturę rdzeniową - IN/OUT stają się słabo połączone z SCC.

Rozkłady stopni

- Rozkłady stopni przy awariach zachowują wcześniejsze właściwości — wykładniki potęgowe są bliskie 0.4 (niskie $R^2 \approx 0.3-0.4$), co sugeruje niewielką zmianę struktury lokalnej.
- W przypadku ataków, rozkłady te ulegają znacznej zmianie:
 - wykładniki in-degree/out-degree spadają do wartości poniżej -1.7 ,
 - współczynniki determinacji R^2 osiągają nawet 0.85,
 - co oznacza, że usunięcie hubów „ujawnia” potęgową strukturę grafu.

Odległości i średnice

- Przy awariach średnie odległości pozostają stabilne (2.6-2.7), a średnice nie przekraczają 9 — co sugeruje zachowanie efektu małego świata.
- Po atakach średnie odległości wzrastają dramatycznie do ponad 5, a średnice sięgają 17-18 — sieć staje się wyraźnie mniej efektywna informacyjnie.

Klasteryzacja

- Globalny współczynnik klasteryzacji utrzymuje się na poziomie ~ 0.7 dla awarii.
- W przypadku ataków spada do $\sim 0.17-0.24$, co świadczy o zerwaniu lokalnych struktur spójnych.

Spójność wierzchołkowa

- Dla awarii, graf pozostaje 1-spójny — nadal występują punkty artykulacji.

- Dla ataków graf ulega dezintegracji, co uniemożliwia analizę rozspajających wierzchołków (graf nie jest już spójny).

Wniosek końcowy

Graf sieci WWW uczelni ma klasyczne właściwości sieci skali bezwzględnej (scale-free) — jest:

- **odporny na awarie** — przypadkowe usunięcia nie zakłócają znacząco funkcjonowania,
- **podatny na ataki** — usunięcie stron centralnych (o najwyższym stopniu) powoduje szybkie rozbitcie całej struktury.

Z punktu widzenia zarządzania infrastrukturą informacyjną, oznacza to konieczność zapewnienia nadmiarowości i kopii zapasowych dla węzłów centralnych (np. strona główna, główne katalogi).

4. PAGERANK


4.1 Analiza PageRank

W ramach analizy rangi stron w grafie WWW zaimplementowano iteracyjny algorytm PageRank, działający w wersji z tłumieniem i bez tłumienia. Obliczenia przeprowadzono dla różnych wartości współczynnika tłumienia d oraz porównano otrzymane rozkłady PageRanku z rozkładem potęgowym.

4.1.1 Rozkład PageRank bez tłumienia ($d = 1.0$)

W przypadku wyłączenia tłumienia, cały przepływ PageRanku opiera się na strukturze linków — węzły końcowe (bez wyjścia) powodują akumulację rankingu. Uzyskano:

Regresja log-log: $y \sim x^{-1.67}$, $R^2 = 0.868$




Rysunek 4.1: Rozkład PageRank bez tłumienia ($d = 1.0$)

4.1.2 Rozkład PageRank z tłumieniem ($d = 0.85$)

Przy zastosowaniu tłumienia (domyślna wartość $d = 0.85$) uzyskano:

Regresja log-log: $y \sim x^{-0.83}$, $R^2 = 0.746$



Rysunek 4.2: Rozkład PageRank z tłumieniem ($d = 0.85$)


Top 5 stron o najwyższym PageRank:

- <https://www.um.edu.mt/> (0.14197)
- <https://www.um.edu.mt...> (0.0103)
- <http://www.um.edu.mt/privacy...> (0.0100)
- <https://www.um.edu.mt/privacy/...> (0.0093)
- <https://www.um.edu.mt/students/...> (0.0075)

4.1.3 Zbieżność PageRank dla różnych wartości tłumienia

Damping = 0.6

- Top 5 stron — max PR: 0.04407
- Regresja log-log: $x^{-0.58}$, $R^2 = 0.667$




Rysunek 4.3: Rozkład PageRank ($d = 0.6$)

Damping = 0.75

- Top 5 stron — max PR: 0.08237


- Regresja log-log: $x^{-0.71}$, $R^2 = 0.707$



Rysunek 4.4: Rozkład PageRank ($d = 0.75$)

Damping = 0.85


- Top 5 stron — max PR: 0.14197
- Regresja log-log: $x^{-0.83}$, $R^2 = 0.746$



Rysunek 4.5: Rozkład PageRank ($d = 0.85$)

Damping = 0.95


- Top 5 stron — max PR: 0.34959
- Regresja log-log: $x^{-1.04}$, $R^2 = 0.799$



Rysunek 4.6: Rozkład PageRank ($d = 0.95$)

Damping = 1.0

- Top 5 stron — max PR: 0.93913
- Regresja log-log: $x^{-1.67}$, $R^2 = 0.868$



Rysunek 4.7: Rozkład PageRank ($d = 1.0$)

4.1.4 Wnioski

- Wartości PageRank podlegają rozkładowi potęgowemu z dość wysokim współczynnikiem determinacji R^2 — potwierdza to typową dla sieci WWW właściwość skali bezwzględnej.
- Zwiększanie współczynnika tłumienia powoduje bardziej wyraźną hierarchizację — wyższe PR dla głównych stron, większe różnice pomiędzy liderami i resztą grafu.
- Najwyższe wartości PR osiągają strony główne domeny uczelni, strony polityki prywatności oraz podstrony pomocy i zasobów — co potwierdza skuteczność algorytmu PageRank w identyfikowaniu najważniejszych zasobów.
- Zbieżność rozkładu PR jest stabilna dla szerokiego zakresu wartości d , co świadczy o poprawności implementacji.

5. PODSUMOWANIE

Badany graf WWW wykazuje wszystkie cechy charakterystyczne dla rzeczywistych, dużych sieci hipertekstowych:

- złożoną strukturę typu *bow-tie*,
- wysoką lokalną klasteryzację i małe średnie odległości,
- odporność na losowe awarie,
- silną podatność na ukierunkowane ataki,
- oraz hierarchiczną strukturę odzwierciedloną w rankingu PageRank.